



Nombre: Yahribel Díaz Hernández.

Matrícula: 2026-0279.

Tema: Codificación de caracteres y tipos de archivos.

Asignatura: Programación para Mecatrónicos.

Profesor: Carlos Antonio Pichardo Viuque.

Codificación de caracteres

La codificación de caracteres es el método informático que convierte el texto legible por humanos (letras, números y símbolos) en valores numéricos binarios (0 y 1) que las computadoras pueden procesar. Actúa como una tabla de traducción fundamental para que los dispositivos almacenen, interpreten y muestren información correctamente.

Entre los que vamos a utilizar en la unidad están:

- **ASCII**

ASCII son las siglas de **American Standard Code for Information Interchange** (Código Estándar Americano para el Intercambio de Información). Es un estándar creado en la década de 1960 para que diferentes tipos de computadoras y dispositivos pudieran comunicarse entre sí sin problemas.

Básicamente, es un traductor: como las computadoras solo entienden de electricidad (ceros y unos), el código ASCII le asigna un número específico a cada letra, número o símbolo. Por ejemplo, cuando presionas una tecla en tu teclado, este envía una combinación de bits (ceros y unos) que la computadora interpreta gracias a este sistema.

¿Cómo se organiza el código?

Existen dos versiones:

1. **ASCII Estándar:** Utiliza 7 bits, lo que permite crear 128 combinaciones diferentes (números del 0 al 127).
2. **ASCII Extendido:** Utiliza 8 bits, lo que amplía la capacidad a 256 combinaciones. Esta versión se creó porque se necesitaban más símbolos y caracteres de diferentes idiomas que no cabían en el estándar original.

Tipos de caracteres

Dentro de los 128 caracteres del código estándar, se dividen en dos grupos:

- **Caracteres de control (Comandos):** Son los primeros 32 caracteres (del 0 al 31) y el último (el 127). Estos no se ven en pantalla; sirven para dar órdenes a la computadora. Un ejemplo es la función de la tecla "borrar" (DEL), que le indica al sistema que debe eliminar el carácter anterior.

- **Caracteres imprimibles:** Son los que sí vemos en pantalla, como las letras (mayúsculas y minúsculas), los números del 0 al 9 y los signos de puntuación. El espacio en blanco también se considera un carácter imprimible porque, aunque no tenga una forma gráfica, ocupa un lugar visible en el texto.

¿Para qué es importante?

- **Programación:** Lenguajes populares como Python, Java o C++ utilizan ASCII para manejar símbolos y textos.
- **Manipulación de datos:** Permite comparar textos, buscar palabras o cambiar el formato de los datos.
- **Entrada y salida:** Es la base para que la computadora entienda lo que escribimos y nos muestre la información correctamente.

- **UTF-8**

UTF-8 son las siglas de **Formato de Transformación Unicode** y es un sistema que convierte los números únicos asignados a cada carácter (llamados puntos de código) en secuencias de ceros y unos que la computadora puede procesar. Su propósito es permitir que las computadoras almacenen y muestren texto de cualquier idioma del mundo, además de símbolos y emojis.

Características principales

- **Compatibilidad con el pasado:** Es totalmente compatible con el antiguo estándar ASCII, lo que significa que cualquier archivo escrito en ASCII puede ser leído correctamente por un decodificador UTF-8.
- **Ancho variable:** A diferencia de otros sistemas, UTF-8 no usa siempre la misma cantidad de espacio; puede usar desde 1 hasta 4 bytes (grupos de 8 bits) según lo complejo que sea el carácter.
- **Eficiencia:** Las letras del alfabeto inglés suelen ocupar solo 1 byte, mientras que idiomas como el chino o los emojis requieren más espacio.

¿Cómo lee el decodificador los caracteres?

El decodificador sabe exactamente cuántos bytes debe leer observando los primeros bits de cada grupo para identificar patrones específicos:

1. **Caracteres de 1 byte:** Si el byte comienza con un 0, el decodificador lo reconoce inmediatamente como un carácter sencillo del estándar ASCII.
2. **Inicio de caracteres largos:** Si comienza con 11, el decodificador entiende que es el "byte líder" de un carácter complejo; la cantidad de "unos" seguidos le indica si el carácter total mide 2, 3 o 4 bytes.
3. **Bytes de continuación:** Si comienza con 10, el sistema sabe que es una pieza que completa a un carácter que empezó en un byte anterior.

Ventajas tecnológicas

Gracias a estas reglas de bits, el decodificador posee auto-sincronización, lo que le permite encontrar el inicio de un carácter incluso si empieza a leer desde la mitad de un archivo o si se pierden datos en una transmisión. Debido a su flexibilidad y capacidad para evitar errores, es el estándar más usado en internet, presente en casi el 98% al 99.9% de las páginas web actuales.

- **UTF-16**

UTF-16 es un esquema de codificación que forma parte del estándar Unicode. Su función es asignar un código específico a los caracteres de casi todos los idiomas del mundo, permitiendo que las computadoras procesen textos complejos que van más allá del alfabeto inglés.

El espacio que utiliza

A diferencia de otros sistemas, el UTF-16 se considera un mecanismo de longitud variable, pero con un rango distinto al de UTF-8. Para representar un solo carácter (como una letra o un símbolo), utiliza:

- **Mínimo 2 bytes** (16 bits).
- **Máximo 4 bytes** (32 bits).

Esto significa que, incluso para los caracteres más simples, siempre utilizará al menos dos grupos de 8 bits.

El problema de la compatibilidad

Una característica fundamental del UTF-16 mencionada en las fuentes es que no es compatible con ASCII.

- Mientras que sistemas como UTF-8 pueden leer archivos viejos escritos en ASCII sin problemas, el UTF-16 no puede traducir el código ASCII directamente.
- Si un archivo fue escrito originalmente en ASCII, un sistema UTF-16 no podrá leerlo correctamente.

Ejemplos de almacenamiento

Para entender cómo ocupa espacio en la memoria, las fuentes dan los siguientes ejemplos:

- **La letra "A":** En este sistema, ocupa 2 bytes de memoria.
- **Caracteres de otros idiomas:** Por ejemplo, la letra "pe" del idioma urdu también ocupa 2 bytes en UTF-16.

Tipos de archivos

Se clasifican principalmente como formatos de estructuración de datos o formatos de intercambio de datos, entre estos:

- **JSON**

JSON son las siglas de **JavaScript Object Notation** (Notación de Objetos de JavaScript). Es un formato de texto sencillo que sirve para guardar y enviar información entre diferentes sistemas, comúnmente entre un servidor web y una aplicación o navegador.

Aunque su nombre menciona JavaScript, es un estándar independiente que funciona con casi todos los lenguajes de programación modernos, como Python, PHP, C++ y Ruby. Actualmente, es el formato favorito de los programadores para intercambiar datos en internet, reemplazando a formatos más antiguos y pesados como el XML.

¿Cómo se organiza la información?

Un archivo JSON (que se reconoce por la extensión .json) sigue reglas de escritura muy estrictas para evitar errores. Su estructura básica se compone de dos elementos principales:

- **Propiedad y Valor:** La información se organiza en parejas. Primero se pone el nombre de lo que queremos definir (propiedad) y luego su contenido (valor), separados por dos puntos. Por ejemplo: "edad": 25.
- **Uso de comillas:** Las propiedades siempre deben ir encerradas en comillas dobles.
- **Símbolos de agrupación:** Se utilizan las llaves { } para contener objetos y los corchetes [] para crear listas o arreglos de datos.
- **Separación por comas:** Cada par de datos se separa del siguiente con una coma, pero es fundamental no poner una coma después del último elemento, ya que esto provocaría un error de lectura.

Tipos de datos que puede guardar

Dentro de un JSON, los valores pueden ser de varios tipos:

- **Texto (Strings):** Siempre entre comillas dobles.
- **Números:** Ya sean enteros o con decimales.
- **Booleanos:** Valores de verdadero (`true`) o falso (`false`).
- **Nulo (null):** Para indicar que un valor está vacío.
- **Arreglos:** Listas ordenadas de elementos.
- **Objetos anidados:** Se puede meter un objeto dentro de otro para organizar información compleja de forma infinita.

¿Por qué es tan popular?

El uso de JSON se ha extendido masivamente por tres razones clave:

1. **Es muy ligero:** Al ser un formato de texto simple, los archivos son pequeños y se transmiten muy rápido por internet.
2. **Es fácil de leer:** Tanto para los humanos como para las computadoras es sencillo entender la estructura de los datos.
3. **Rapidez:** Las computadoras pueden procesar archivos JSON mucho más rápido que otros formatos, lo que hace que las páginas web y aplicaciones carguen en menos tiempo.

- **XML**

El XML (que significa Lenguaje de Marcas Extensible) es un formato de archivo diseñado para almacenar y transportar información de manera organizada. A diferencia de una conversación normal entre personas, el XML utiliza reglas y una estructura específica para que dos aplicaciones o computadoras diferentes puedan "hablar" entre sí e intercambiar datos sin errores.

Características:

1. El uso de etiquetas (Tags)

La base del XML son las etiquetas, que se escriben entre paréntesis angulares < >.

- **Son personalizables:** A diferencia de otros lenguajes (como el HTML), en XML las etiquetas **no están predefinidas**; tú puedes inventar los nombres de las etiquetas según lo que necesites (por ejemplo: <nombre>, <amigo> o <precio>).
- **Deben cerrarse:** Cada vez que abres una etiqueta para empezar un dato, debes cerrarla con una barra inclinada / para indicar que el dato terminó (ejemplo: <nombre>Alex</nombre>). Si olvidas cerrar una etiqueta, el archivo dará un error y no podrá ser procesado.

2. Estructura organizada (Jerarquía)

La información en un XML se organiza como un **árbol**.

- **Etiqueta raíz:** Todo archivo XML debe comenzar con una única etiqueta principal que encierra a todas las demás.
- **Etiquetas anidadas (Hijos):** Dentro de una etiqueta principal, puedes meter otras etiquetas "hijas" para dar más detalles. Por ejemplo, dentro de una etiqueta <usuario> puedes tener etiquetas para su <nombre>, <documento> y <fecha>.

3. Es "Universal" y fácil de leer

Una de las mayores ventajas del XML es que **es** independiente de la plataforma. Esto significa que una aplicación creada con una tecnología antigua puede enviar un XML a una aplicación

moderna y ambas se entenderán perfectamente. Además, el formato está hecho para que sea legible tanto por humanos como por máquinas; si abres un archivo .xml en un bloc de notas, podrás entender fácilmente qué información contiene.

4. Validación y reglas

Para asegurar que un archivo XML esté bien construido, se utilizan herramientas de validación. Los desarrolladores suelen crear unos archivos llamados XSD o DTD, que funcionan como un manual de instrucciones o "gramática" para el XML. Estos archivos definen qué etiquetas son obligatorias, en qué orden deben ir y qué tipo de datos (números o texto) deben contener.

- **CSV**

Las siglas CSV significan **Comma Separated Values**, que en español se traduce como Valores Separados por Comas. Esencialmente, es un archivo de texto plano que utiliza una estructura muy sencilla para almacenar datos de forma organizada.

¿Cómo se organiza la información?

Aunque por dentro es solo texto, la computadora lo interpreta como si fuera una tabla o una planilla de cálculos. Su estructura sigue estas reglas:

- **Filas y Columnas:** Cada renglón o línea del archivo representa una fila, y cada valor dentro de esa línea representa una columna.
- **El Separador:** La característica principal es que los datos de una misma fila se separan mediante comas. En algunos casos, dependiendo de la necesidad, también se pueden usar puntos y comas.
- **Títulos:** Normalmente, la primera línea del archivo se utiliza para poner los nombres de las columnas (por ejemplo: Nombre, Apellido, Nota).
- **Extensión:** Estos archivos se identifican fácilmente porque terminan en .csv.

¿Para qué se utiliza?

Los archivos CSV son extremadamente comunes en la informática por varias razones:

- **Intercambio de datos:** Permiten que dos sistemas o bases de datos diferentes (como MySQL y SQL Server) compartan información de forma sencilla, actuando como un puente entre ellos.
- **Grandes cantidades de información:** Son ideales para trabajar con mucha información de manera rápida y simple.
- **Compatibilidad con Excel:** Se pueden abrir y editar fácilmente en programas de hojas de cálculo como Excel, lo que facilita su lectura para las personas.

Datos importantes a tener en cuenta

- **Números con decimales:** Si se guardan números con decimales, es recomendable usar un punto para los decimales (ejemplo: 3.75) para no confundirlos con la coma que separa las columnas.
- **Procesamiento:** Para las computadoras, leer estos archivos es muy rápido, aunque para un programador puede ser un poco más complejo extraer los datos exactos debido a que debe "separar" el texto cada vez que encuentra una coma.